Análisis Estadístico de Datos - Taller 02

Adriana Porras, Alejandra Niño, Bayron Morales, Juliana Cárdenas

EIA data

U.S. Energy Information Administration (EIA) es una organización que se encarga de recopilar, analizar y difundir información energética de manera independiente e imparcial para promover la formulación de políticas sólidas, mercados eficientes y la comprensión pública de la energía y su interacción con la economía y el medio ambiente.

Los datos que trabajaremos a continuación corresponden a la extracción de diferentes variables relacionadas con energías renovables y combustibles fósiles, las UE son 111 países de todos los continentes del mundo, seleccionados para fines académicos por ser aquellos países que presentan mayor cantidad de información de análisis.

El objetivo de este análisis es encontrar diferentes relaciones entre los países que se están estudiando, de tal forma que podamos caracterizar en términos de importación, exportación, consumo, producción, etc. a los países de estudio.

```
# Instalación de librerias en caso de no tenerlas
# install.packages("plotly")
# install.packages("MASS")
# install.packages("psych")
# install.packages("tidyverse")
# install.packages("factoextra")
# install.packages("GGally")

# Ejecución de librerias
library(plotly)
library(MASS)
library(psych)
library(tidyverse)
library(factoextra)
library(GGally)
```

```
# Colores usados en todos los gráficos del taller
rojo        <- "#DA0921"
rojo_oscuro <- "#950606"
```

```
data1 <- read.csv("datos_taller_02.csv", row.names=1, sep=";")

# Revisar variables en la base
names(data1)
```

```
##  [1] "Bunker_fuel_consumption_TBPD"
##  [2] "Bunker_residual_fuel_oil_consumption_TBPD"
##  [3] "Crude_oil_including_lease_condensate_exports_TBPD"
```

```
##  [4] "Crude_oil_including_lease_condensate_imports_TBPD"
##  [5] "Crude_oil_including_lease_condensate_production_TBPD"
##  [6] "Crude_oil_including_lease_condensate_reserves_BB"
##  [7] "Distillate_fuel_oil_consumption_TBPD"
##  [8] "Distillate_fuel_oil_production_TBPD"
##  [9] "Jet_fuel_consumption_TBPD"
## [10] "Jet_fuel_production_TBPD"
## [11] "Kerosene_consumption_TBPD"
## [12] "Kerosene_production_TBPD"
## [13] "Liquefied_petroleum_gases_.LPG._consumption_TBPD"
## [14] "Liquefied_petroleum_gases_.LPG._production_TBPD"
## [15] "Motor_gasoline_consumption_TBPD"
## [16] "Motor_gasoline_production_TBPD"
## [17] "Natural_gas_plant_liquids_production_TBPD"
## [18] "Other_liquids_production_TBPD"
## [19] "Other_refined_products_consumption_TBPD"
## [20] "Other_refined_products_production_TBPD"
## [21] "Petroleum_and_other_liquids_CO2_emissions_MMTCD"
## [22] "Petroleum_and_other_liquids_consumption_TBPD"
## [23] "Petroleum_and_other_liquids_production_TBPD"
## [24] "Refined_petroleum_products_consumption_TBPD"
## [25] "Refined_petroleum_products_production_TBPD"
## [26] "Refinery_processing_gain_TBPD"
## [27] "Residual_fuel_oil_consumption_TBPD"
## [28] "Residual_fuel_oil_production_TBPD"
## [29] "Biomass_and_waste_electricity_installed_capacity_MK"
## [30] "Biomass_and_waste_electricity_net_generation_BKWH"
## [31] "Electricity_distribution_losses_BKWH"
## [32] "Electricity_exports_BKWH"
## [33] "Electricity_imports_BKWH"
## [34] "Electricity_installed_capacity_MK"
## [35] "Electricity_net_consumption_BKWH"
## [36] "Electricity_net_generation_BKWH"
## [37] "Electricity_net_imports_BKWH"
## [38] "Fossil_fuels_electricity_installed_capacity_MK"
## [39] "Fossil_fuels_electricity_net_generation_BKWH"
## [40] "Geothermal_electricity_installed_capacity_MK"
## [41] "Geothermal_electricity_net_generation_BKWH"
## [42] "Hydroelectric_pumped_storage_electricity_installed_capacity_MK"
## [43] "Hydroelectric_pumped_storage_electricity_net_generation_BKWH"
## [44] "Hydroelectricity_installed_capacity_MK"
## [45] "Hydroelectricity_net_generation_BKWH"
## [46] "Non.hydro_renewable_electricity_installed_capacity_MK"
## [47] "Non.hydro_renewable_electricity_net_generation_BKWH"
## [48] "Nuclear_electricity_installed_capacity_MK"
## [49] "Nuclear_electricity_net_generation_BKWH"
## [50] "Renewable_electricity_installed_capacity_MK"
## [51] "Renewable_electricity_net_generation_BKWH"
## [52] "Solar_electricity_installed_capacity_MK"
## [53] "Solar_electricity_net_generation_BKWH"
## [54] "Tide_and_wave_electricity_installed_capacity_MK"
## [55] "Tide_and_wave_electricity_net_generation_BKWH"
## [56] "Wind_electricity_installed_capacity_MK"
## [57] "Wind_electricity_net_generation_BKWH"
```

Normal multivariada

Pregunta 1. Encuentre la estimación del vector de medias y la matriz de varianzas y covarianzas para 5 variables de su interés del conjunto de datos.

Las 5 variables seleccionadas son:

- Electricity_net_consumption_BKWH (35)
- Electricity_net_generation_BKWH (36)
- Electricity_distribution_losses_BKWH (31)
- Fossil_fuels_electricity_net_generation_BKWH (39)
- Renewable_electricity_net_generation_BKWH (51)

```
data2 <- data1[c(35:36,31,39,51)]

# Se ajustan los nombres para facilitar la visualización
names(data2) <- c("Consumo(C)", "Generacion(G)","Perdida(P)",
                  "Fossil_G", "Renewable_G")

names(data2)
```

```
## [1] "Consumo(C)"    "Generacion(G)" "Perdida(P)"    "Fossil_G"
## [5] "Renewable_G"
```

```
# Vector de medias
colMeans(data2)
```

```
##    Consumo(C) Generacion(G)    Perdida(P)      Fossil_G   Renewable_G
##     181.81592     198.29009      17.00450     132.58408      44.77117
```

Es necesario resaltar que las cinco variables seleccionadas manejan la misma escala, ya que se presentan en BKWH (Billion Kilowatt Hours (Miles de millones de kilovatios-hora)). Respecto al vector de medias, la generación neta de electricidad es la que tiene la mayor media (Generación(G): 198.290 BKWH), seguido por el consumo neto de electricidad (Consumo(C): 181.816 BKWH) y la generación neta de electricidad a partir de combustibles fósiles (Fossil_G: 132.584). La generación neta de electricidad renovable tiene una media de 44,771 y la media más baja la tienen las pérdidas en la distribución de electricidad. Esta última variable representa la diferencia entre la energía eléctrica que se inyecta en la red de distribución y la energia que finalmente se entrega a los consumidores finales.

```
# Matriz de varianzas y covarianzas:
cov(data2)
```

```
##              Consumo(C) Generacion(G) Perdida(P)  Fossil_G Renewable_G
## Consumo(C)     383958.82     408034.46  25162.312 290441.49   82086.952
## Generacion(G)  408034.46     434094.97  27076.711 308733.29   87623.857
## Perdida(P)      25162.31      27076.71   1990.936  19210.37    5578.751
## Fossil_G       290441.49     308733.29  19210.368 223824.71   60829.937
## Renewable_G     82086.95      87623.86   5578.751  60829.94   20864.464
```

La variable que presenta mayor varianza es consumo neto de electricidad (Consumo(C): 383958) y la que presenta menor varianza es pérdidas en la distribución de electricidad (Perdida(P): 1990.936). Sin embargo, se debe recordar que esta se ve afectada por valores atípicos, por lo que puede estar sobrestimada.

Respecto a las covarianza, se observa que todas las variables se relacionan positivamente, es decir, que al aumentar una, las otras también aumentarán. Para poder medir la fuerza de esa relación, se requiere realizar un análisis de correlación, el cual se realizará en el siguiente punto.

ACP

Pregunta 2. Realice un análisis descriptivo univariado y bivariado del conjunto de datos. Considere nuevamente las mismas 5 variables de su interés para este punto.

Análisis descriptivo univariado

Para realizar el análisis descriptivo univariado se van a emplear boxplot, por lo que se genera una función que permita realizarlo de forma fácil y, a continuación, se generan y analizan cada uno de los boxplot.

```
# Crear una función para crear boxplot

boxplot_estadisticos <- function(data2, variable, titulo, subtitulo, etiqueta_x) {

  valores <- data2[[variable]]

  estadisticos <- boxplot.stats(valores)$stats

  etiquetas <- data.frame(
    x = as.numeric(estadisticos),
    y = 1.18,
    etiqueta = c(
      paste0("Mín: ", round(estadisticos[1], 1)),
      paste0("Q1: ", round(estadisticos[2], 1)),
      paste0("Q2: ", round(estadisticos[3], 1)),
      paste0("Q3: ", round(estadisticos[4], 1)),
      paste0("Máx: ", round(estadisticos[5], 1))))

  ggplot(data2, aes(x = .data[[variable]], y = 1)) +

    geom_boxplot(
      fill = rojo,
      color = rojo_oscuro,
      width = 0.35) +

    geom_segment(
      data = etiquetas,
      aes(
        x = x,
        xend = x,
        y = 0.82,
        yend = 1.18
      ),
      color = rojo_oscuro,
```

```
      linewidth = 0.5,
      linetype = "dashed") +

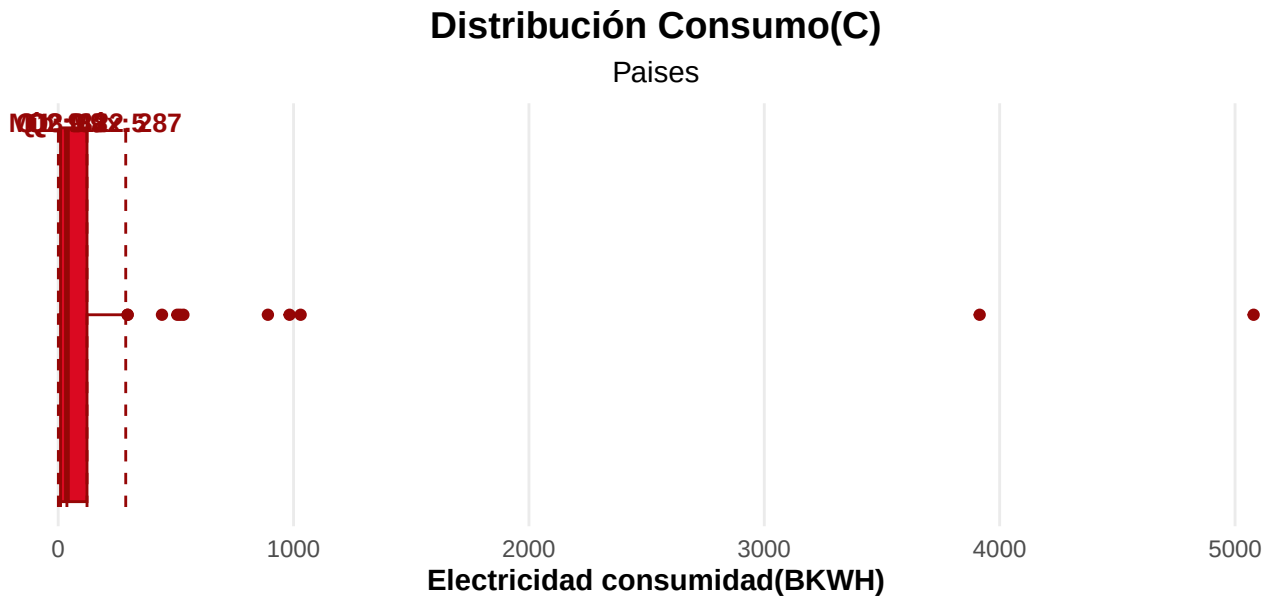
    geom_text(
      data = etiquetas,
      aes(
        x = x,
        y = y,
        label = etiqueta
      ),
      size = 3.5,
      fontface = "bold",
      color = "#950606") +

    labs(
      title = titulo,
      subtitle = subtitulo,
      x = etiqueta_x,
      y = NULL) +

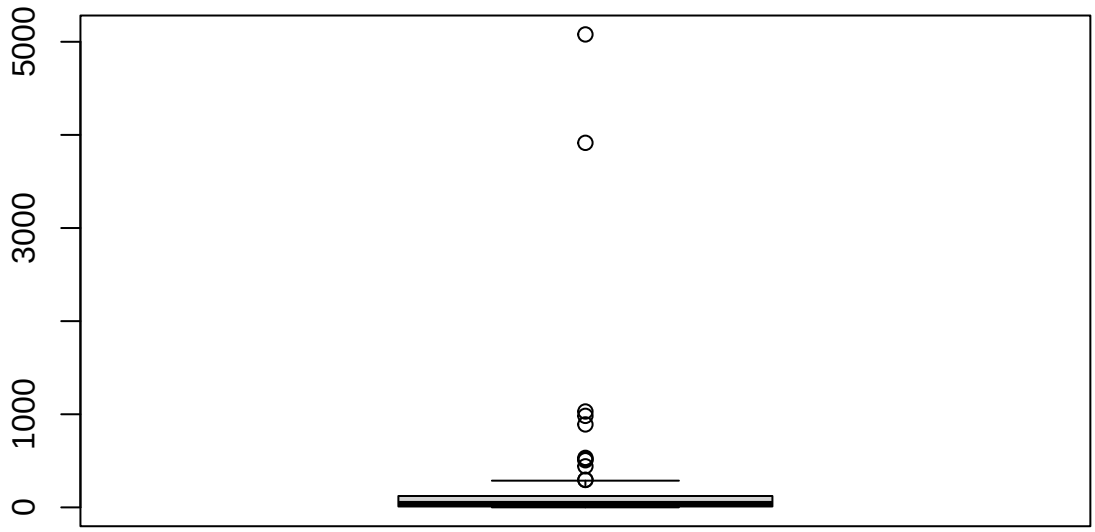
    theme_minimal() +

    theme(
      plot.title = element_text(
        face = "bold",
        size = 14,
        hjust = 0.5),
      plot.subtitle = element_text(
        size = 11,
        hjust = 0.5),
      axis.text.y = element_blank(),
      axis.ticks.y = element_blank(),
      axis.title.y = element_blank(),
      axis.title.x = element_text(face = "bold"),
      panel.grid.minor = element_blank(),
      panel.grid.major.y = element_blank())}
```

```
boxplot_estadisticos(
 data2,
  "Consumo(C)",
  "Distribución Consumo(C)",
  "Paises",
  "Electricidad consumidad(BKWH)")
```




```
caja_Consumo <- boxplot(data2$`Consumo(C)`, plot = TRUE)
```




```
caja_Consumo$stats
```

```
##         [,1]
```

```
## [1,]   0.80
## [2,]   9.95
## [3,]  37.00
## [4,] 122.50
## [5,] 287.00
```

```
length(caja_Consumo$out)
```

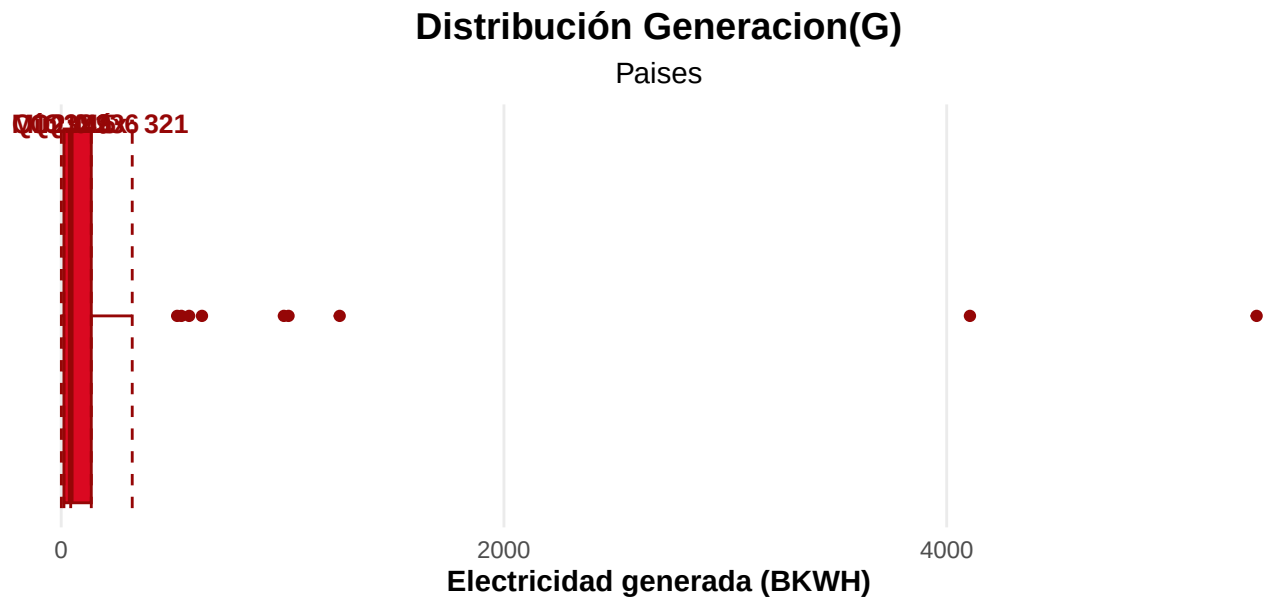
```
## [1] 11
```

```
max(data2$`Consumo(C)`)
```

```
## [1] 5079
```

En el punto anterior se identificó que la media de la generación neta de electricidad es de 198.290 BKWH, este valor dista bastante de la mediana (Q2): 37, debido a que la media es sensible a valores atípicos y, en este caso, se observan 11 datos atipicos con valores muy extremos.

```
boxplot_estadisticos(
 data2,
  "Generacion(G)",
  "Distribución Generacion(G)",
  "Paises",
  "Electricidad generada (BKWH)")
```




```
caja_Generacion <- boxplot(data2$`Generacion(G)`, plot = FALSE)

caja_Generacion$stats
```

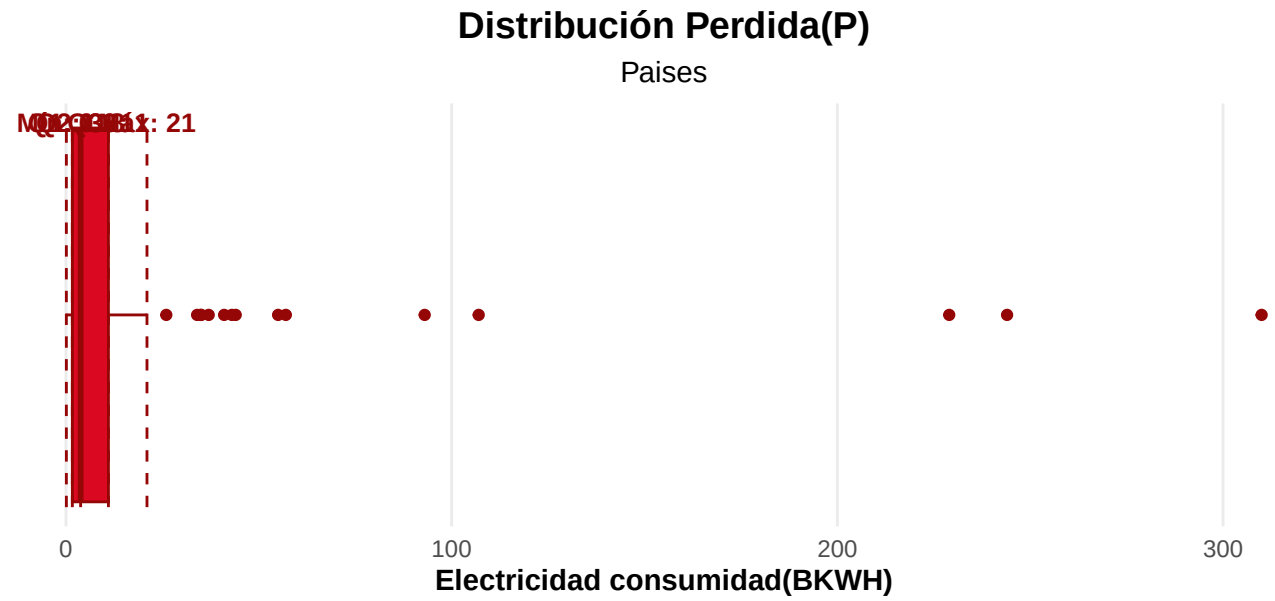
```
##       [,1]
## [1,]   0.9
## [2,]  12.5
## [3,]  43.0
## [4,] 136.0
## [5,] 321.0
```

```
length(caja_Generacion$out)
```

```
## [1] 9
```

.....

```
boxplot_estadisticos(
 data2,
  "Perdida(P)",
  "Distribución Perdida(P)",
  "Paises",
  "Electricidad consumidad(BKWH)")
```




```
caja_Perdida <- boxplot(data2$`Perdida(P)`, plot = FALSE)

caja_Perdida$stats
```

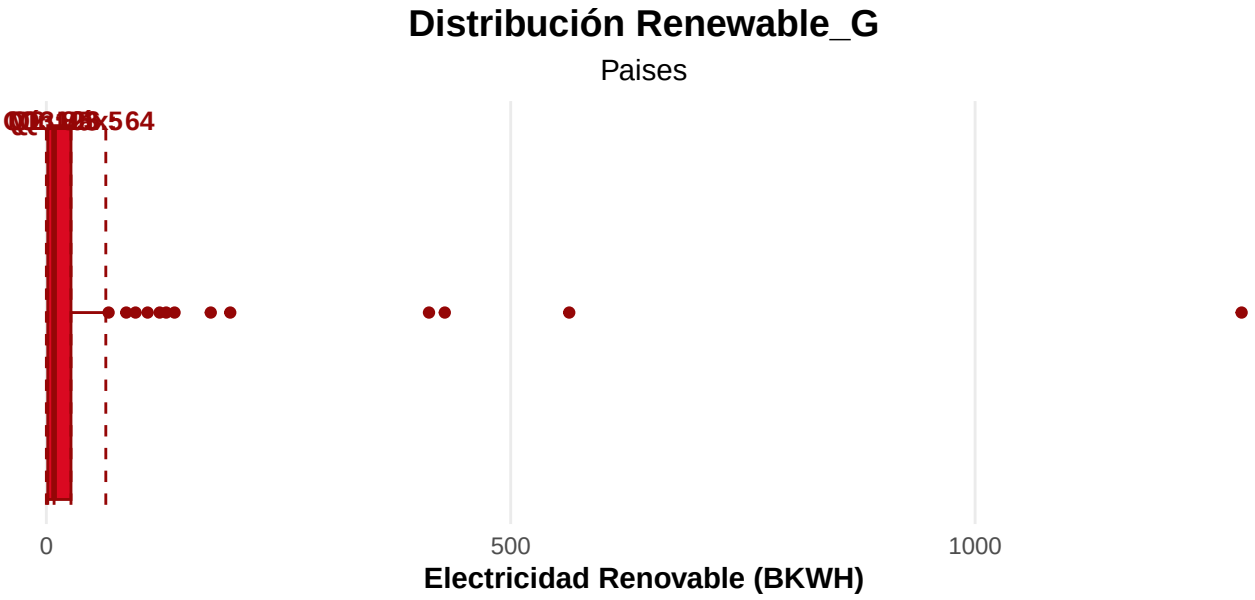
```
##       [,1]
## [1,]  0.10
## [2,]  1.65
## [3,]  3.80
## [4,] 11.00
## [5,] 21.00
```

```r
length(caja_Perdida$out)
```

```
## [1] 15
```

.....

```r
boxplot_estadisticos(
 data2,
  "Renewable_G",
  "Distribución Renewable_G",
  "Paises",
  "Electricidad Renovable (BKWH)")
```




```r
caja_Renewable_G <- boxplot(data2$Renewable_G, plot = FALSE)

caja_Renewable_G$stats
```

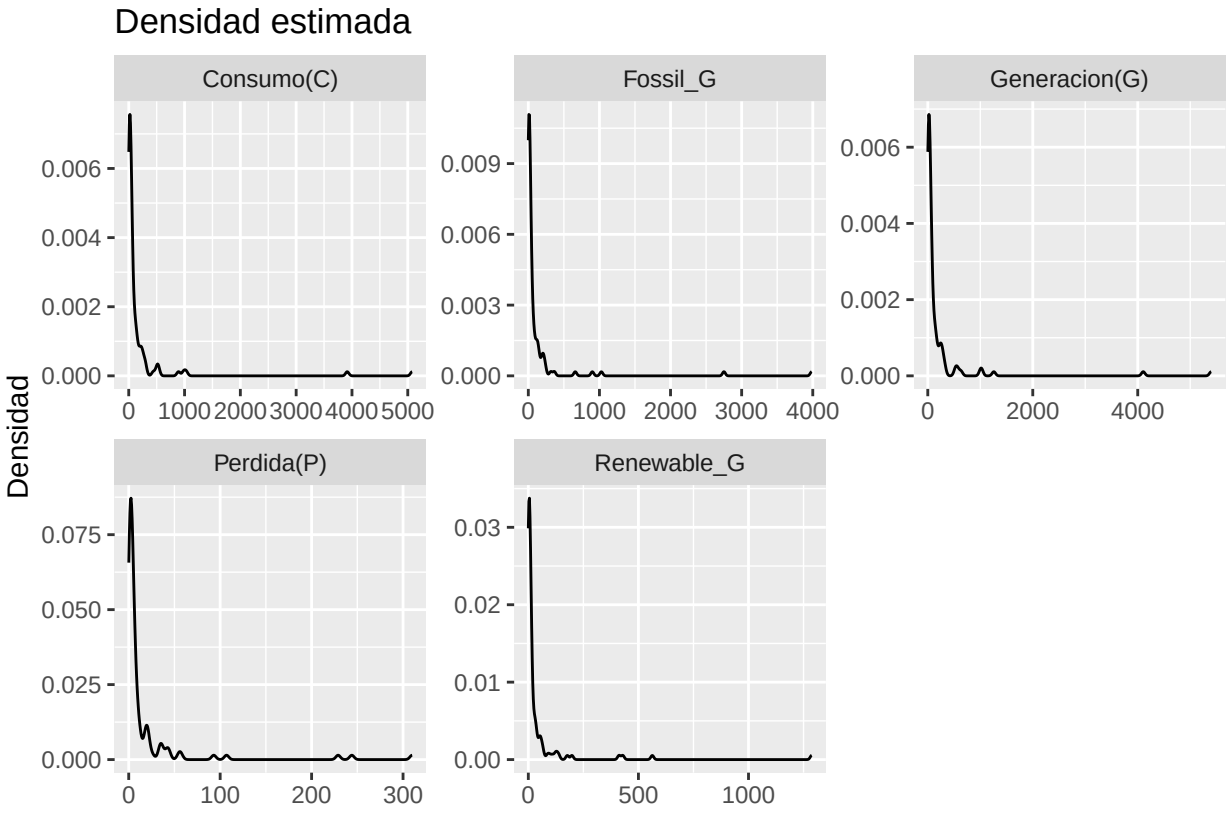
```
##      [,1]
## [1,]  0.0
## [2,]  1.5
## [3,]  8.3
## [4,] 26.5
## [5,] 64.0
```

```r
length(caja_Renewable_G$out)
```

```
## [1] 13
```

.....

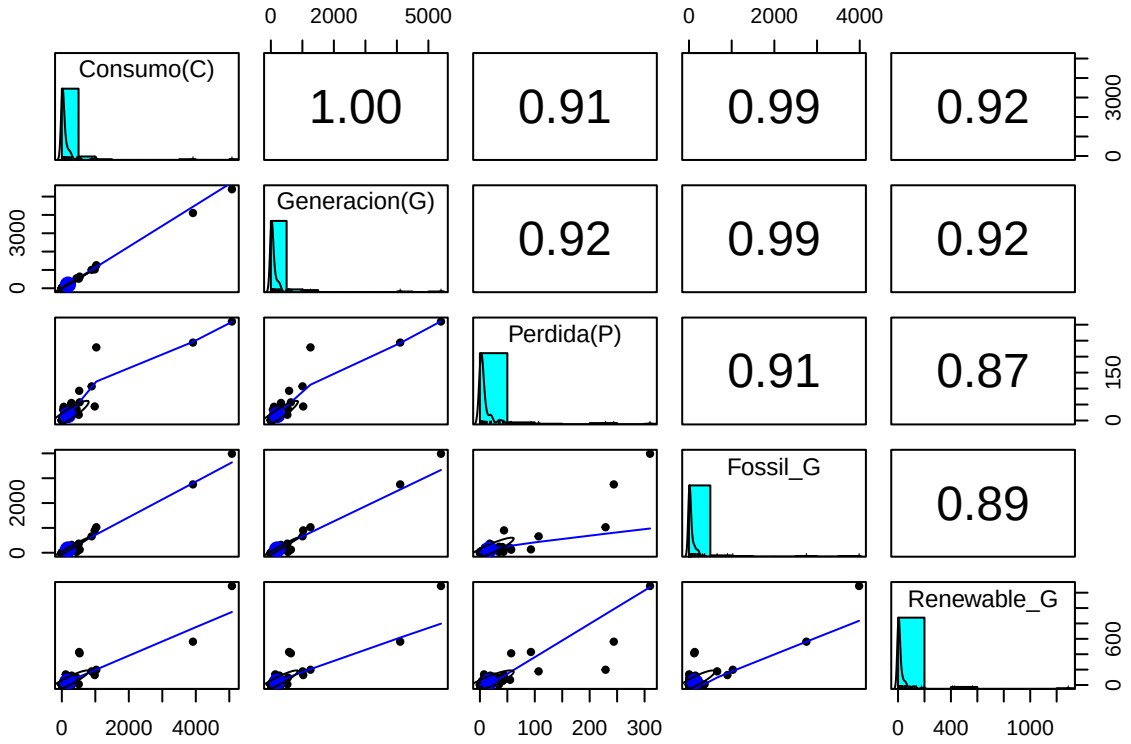
```r
gather(data2) %>%
  ggplot(aes(x=value)) +
  geom_density() +
  labs(x= "",y='Densidad',title="Densidad estimada") +
  facet_wrap(~key, scales = "free")
```



Análisis descriptivo multivariado

.....

```r
pairs.panels(data2,
             scale = FALSE,      # If TRUE, scales the correlation text font
             density = TRUE,     # If TRUE, adds density plots and histograms
             method = "pearson", # Correlation method (also "spearman" or "kendall")
             cor = TRUE,         # If TRUE, reports correlations
             jiggle = FALSE)     # If TRUE, data points are jittered
```



.....

Pregunta 3. El conjunto de datos incluye 57 variables, analizarlas de forma individual podría representar un gasto computacional y de tiempo bastante agotador; por lo cuál una técnica de reducción de dimensionalidad sería ideal. Ejecute un ACP sobre estos datos, compare la contribución de las variables sobre el primer plano factorial de un ACP normado (escalado) y uno sin normalizar (sin escalar).

Pregunta 4. Una vez calculado el PCA normado, ¿qué número de componentes principales deberíamos seleccionar? ¿Bajo que criterio seleccionó este número de componentes?

Pregunta 5. Analice la representación de las variables originales sobre las dos primeras componentes en el primer plano factorial. ¿Que conclusiones podemos sacar de este análisis?

Pregunta 6. Ahora examine con detenimiento el mapa de individuos sobre los planos factoriales que conforman las componentes (1,2) y (2,3). ¿Qué conclusiones puede sacar según la cercanía de algunas UE?

Pregunta 7. Como hemos observado en clase, el ACP es una técnica bastante sensible a datos atípicos, ejecute nuevamente el ACP retirando del conjunto de datos a Estados Unidos, China, Arabia Saudi y Rusia. ¿En que cambia el ACP al excluir estos países?. ¿Se perciben clusters de países con mayor claridad?. Calcule únicamente el ACP normado.

Clustering

Pregunta 8. De acuerdo a lo aprendido en la clase de agrupamiento, utilice el primer plano factorial para determinar de manera aproximada el número de grupos en el análisis. ¿Cuántos clusters espera que existan en el conjunto de datos?

Pregunta 9. Mediante el método de reducción de varianza explicada, determine un número fijo de clusters para su análisis. No tiene que ser el mismo número que el elegido por su compañero, recuerde que ninguno conoce las etiquetas reales de los grupos de los países.

Pregunta 10. Determine mediante k-means y aglomeración jerárquica (usando enlace promedio) la clasificación en grupos para los países de estudio. Considere todas las variables de estudio ¿son diferentes los resultados de los dos análisis cluster?

Pregunta 11. Grafique mediante boxplot la distribución de las 5 variables seleccionadas en el punto 2 diferenciando por los grupos encontrados mediante k-means (es decir, obtenga un boxplot por variable y por grupo: si por ejemplo k-means indica un total de 3 grupos, realice 3 boxplots, uno por grupo, para cada una de las 5 variables). ¿Observa diferencias importantes entre las distribuciones por grupos de la misma variable?